

인공지능 데이터 전처리 결과서

스팀 게임 리뷰를 쓴 그 순간, 이 사람이 게임을 계속할지 그만둘지 예측하기 위한 데이터 준비 과정과 그 근거.

전처리 v1.2

대상 steam_raw.csv · 2026-08-25 07:30 UTC 수집

작성 2026-08-25 · 수정 2026-08-26 담당 데이터 A

목차

- 개요
- 원본 28열 처리
- 신규 생성 15열
- 행 제거 내역
- 변수 묶음 두 종류
- 최종 컬럼 30열
- 재현성·버전
- 후속 확인 항목

1 개요

원본 행	전처리 결과	원본 열	최종 열	이탈률
139,667	139,658	28	30	41.1%

구 분	개 수	설 명
원본 그대로 유지	15열	식별자·범주형·불리언
변환 후 대체	5 → 6열	단위 변환·로그 변환·파생 분리
데이터 누수로 제외	8열	정답에 사용했거나 미래 정보
신규 생성	15열	정답 1 + 파생 14

정답(라벨)은 `churn` 이며 이탈 41.1% / 잔존 58.9% 입니다.

원 칙

전처리는 `preprocess.py` 한 파일에서만 수행합니다. 라벨과 파생 변수를 다른 곳에서 다시 만들지 않습니다. 정의가 갈라지면 조용히 어긋나기 때문입니다.

2 원본 28열 처리 내역

2-1. 그대로 유지 – 15열

컬 럼	처 리	비 고
recommendationid	유지	리뷰 식별. 모델 입력 아님
appid · steamid	유지	게임·유저 식별. 모델 입력 아님
game	유지	식별 + A셋 변수. 60종
genre_group	유지	5종
era	유지	4종
grade	유지	4종
release_year	문자형 변환	숫자가 아닌 범주로 취급. 18종
language	유지	30종
review	유지	딤러닝 입력용 원문
voted_up	True/False → 1/0	81.8%
steam_purchase	True/False → 1/0	86.2%
received_for_free	True/False → 1/0	2.7%
early_access	True/False → 1/0	5.0%
steam_deck	True/False → 1/0	1.4%

2-2. 변환 후 대체 – 5열 → 6열

원 본	대 체 컬 럼	변 환 내 용
playtime_at_review_min	hours_at_review log_hours_at_review	분 → 시간. 값 범위가 0.08 ~ 22,013시간(27만 배) 이 라 로그 변환 병행
num_games_owned	log_num_games is_private	0은 게임 0개가 아니라 프로필 비공개(51.5%) . 0을 결 측으로 바꾸고 로그 변환, 비공개 여부를 별도 컬럼으로 분리. 비공개는 -1로 표시
num_reviews	log_num_reviews	1 ~ 25,164건 → 로그 변환
created_ts app_release_ts	game_age_days	리뷰 시각 – 게임 출시일. 출시 후 며칠째에 쓴 리뷰인가 (112 ~ 9,036일)

2-3. 데이터 누수로 제외 – 8열

정답을 만드는 데 사용했거나, 리뷰 작성 시점에는 존재하지 않았던 정보입니다.

제 외 컬 럼	제 외 근 거
playtime_forever_min	정답 그 자체 . 이 값에서 정답을 계산했으므로 입력에 넣으면 답을 보고 푸는 것
playtime_2weeks_min	최근 2주 플레이 – 미래 정보
last_played_ts	마지막 접속 시각 – 미래 정보
updated_ts	리뷰 수정 시각 – 작성 이후의 사건
votes_up	다른 유저의 추천 수 – 작성 시점엔 0
votes_funny	다른 유저의 "웃김" 수 – 동일
comment_count	댓글 수 – 동일
weighted_vote_score	스팀이 매긴 도움됨 점수 – 동일

▶ 검증 – 일부러 누수시켜 보았 습 니 다

제외한 `playtime_forever_min` 을 입력에 넣어 학습해 비교했습니다.

조 건	ROC-AUC	판 정
누수 컬럼 포함	0.998	정답을 보고 답한 결과
정상 (누수 제외)	0.820	실제 예측

차 단 방 식

금지 컬럼 목록을 코드에 상수(`LEAK_COLS`)로 정의하고, 학습 직전 `assert_no_leak()` 을 호출해 하나라도 섞이면 오류를 발생시킵니다. 사람이 기억하는 대신 코드가 막습니다.

3 신규 생성 15열

3-1. 정답 – 1열

컬 럼	계 산 식	결 과
<code>churn</code>	(총 플레이시간 - 리뷰 시점 플레이시간) < 1시간 → 1	이탈 41.1%

관측 창(리뷰 작성 후 180~545일)은 수집 단계에서 이미 적용되었습니다. 리뷰를 쓴 지 얼마 안 된 사람은 아직 더 플레이할 시간이 없어 자동으로 이탈로 찍히기 때문입니다.

▶ 이탈률 **41.1%** 가 뜻 하는 것

우리가 선정한 60개 게임에서, 관측 창 안에 리뷰를 작성한 139,658명 중, 리뷰 작성 이후 추가 플레이가 1시간 미만인 사람의 비율입니다.

부 정 확 한 표 현	이 유
"스팀 유저의 41%가 이탈한다"	리뷰를 작성한 사람만 대상입니다. 리뷰 작성자는 전체 유저의 일부입니다
"게임 유저의 41%가 이탈한다"	우리가 선정한 60개 게임 에 한정됩니다
"41%가 게임을 영구히 그만두었다"	"해당 리뷰 이후 1시간 미만" 입니다. 이후 복귀 가능성은 배제하지 못합니다

▶ **41.1%** 는 대 췌 값 으 로 사 용 할 수 없 습 니 다

	값	게 임
최저	9.7%	Trailmakers
최고	88.8%	We Were Here Expeditions
게임별 중앙값	47.1%	—
게임별 표준편차	20.0%p	—

전체 평균(41.1%)과 게임별 중앙값(47.1%)이 6%p 차이납니다. 리뷰 수가 많은 게임일수록 이탈률이 낮기 때문입니다(상관 -0.47). 리뷰 수가 많은 게임이 전체 행에서 큰 비중을 차지해 평균을 끌어내립니다. 따라서 보고 시에는 평균 하나가 아니라 분포와 함께 제시합니다.

▶ 라 벨 의 한 계 - "이 탈"의 의 미 가 장 르 마 다 다 릅 니 다

게임 평가등급별 이탈률에서 예상과 반대되는 결과가 나왔습니다.

게 임 평 가	이 탈 률
매우긍정	37.6%
대체로긍정	39.1%
평가나쁨	43.6%
압도적긍정	46.4%

평가가 가장 좋은 게임의 이탈률이 가장 높습니다. 장르를 고정해도 동일합니다.

	멀 티 / 경 쟁	싱 글 서 사
매우긍정	20.7%	56.6%
압도적긍정	35.2%	63.7%

멀티/경쟁은 게임이 좋으면 계속합니다. 종료 지점이 없기 때문입니다. **싱글 서사**는 게임이 좋으면 끝까지 진행한 뒤 종료합니다.

즉 현재 라벨은 "**흥미를 잃고 이탈**" 과 "**완주 후 종료**" 를 구분하지 못합니다. 구분하려면 게임 별 평균 클리어 시간 등 추가 정보가 필요하며, 이는 현재 수집 범위 밖입니다.

3-2. 수치 변환 — 4열

컬럼	계산식	최소	중앙	최대
hours_at_review	분 ÷ 60	0.08	13.07	22,013
log_hours_at_review	log(1+시간)	0.08	2.64	10.00
log_num_games	log(1+보유수), 비공개 -1	-1	-1	10.52
log_num_reviews	log(1+리뷰수)	0.69	2.20	10.13

3-3. 맥락 — 2열

컬럼	계산식	분포
game_age_days	리뷰 시각 - 게임 출시일	112 / 2,538 / 9,036일
is_private	보유 게임 수가 0인가	51.5% 비공개

3-4. 리뷰 텍스트에서 추출 — 7열

언어를 이해하지 않고도 모든 언어에서 동일하게 추출 가능한 신호입니다.

컬럼	계산식	분포 / 비율
review_len	글자 수	0 / 45 / 8,000
review_words	단어 수	0 / 7 / 1,775
review_len_z	언어별 정규화된 길이 (아래)	-0.16 / 0.00 / 10.00
has_text	본문이 있는가	99.6%
excl_ratio	느낌표 비율	중앙 0.00
caps_ratio	대문자 비율 (알파벳 중)	중앙 0.01
has_repeat	같은 글자 4회 이상 반복 (ㅋㅋㅋㅋ, !!!!)	6.1%

▶ 리뷰 길이를 언어별로 정규화한 이유

글자 수가 언어마다 전혀 다른 의미를 가집니다.

언어	글자 수 중앙값
일본어	81자
영어	57자
러시아어	45자
중국어(간체)	17자
한국어	15자

영어가 한국어의 약 4배입니다. 한자·한글이 정보 밀도가 높기 때문입니다. 글자 수를 그대로 사용하면 모델이 "한국어·중국어 리뷰는 성의가 없다"고 잘못 학습합니다.

$$\text{review_len_z} = (\text{글자수} - \text{해당 언어 중앙값}) \div \text{전 언어 공통 표준편차}$$

기준값은 lang_stats.json에 저장하여, 화면(Streamlit)에서도 동일한 기준을 사용합니다.

▶ 표본이 적은 언어 처리 - 팀 검토 중 두 차례 발견하여 수정

설계 초안은 언어별로 중앙값과 표준편차를 모두 계산했습니다. 표본이 적은 언어에서 두 가지 문제가 연달아 나왔습니다.

차 수	발 건	증 상
1차	아랍어 1건 → 표준편차 계산 불가, 대체값 1.0	200자 리뷰의 z 가 197
2차	노르웨이어 197건이 전부 짧음 → 표준편차 75	2000자 리뷰의 z 가 26.5 같은 2000자가 영어에서는 3.6

2차는 표본 하한만으로는 막을 수 없는 문제입니다. 노르웨이어는 197건으로 하한(30건)을 여유 있게 넘겼지만, 그 197건이 모두 짧아서 표준편차가 과소추정됐습니다.

핵심 문제

언어끼리 값을 비교할 수 없다는 것입니다. 이 변수의 목적이 "언어차를 걷어내고 길이만 보기" 인데, 정반대 결과가 나왔습니다.

해결 — 언어별 표준편차를 쓰지 않고 전 언어 공통 표준편차를 씁니다. 언어마다 다르게 쓰는 것은 기본 길이(중앙값)뿐입니다. 성능을 실측해 확인한 뒤 결정했습니다.

표준편차 방식	노르웨이어 2000자	영어 2000자	격차	로지스틱	부스팅
언어별 (초안)	26.50	3.62	7.3배	0.7647	0.8181
전체의 30% 하한	10.00	3.62	2.8배	0.7647	0.8176
전체의 50% 하한	7.81	3.62	2.2배	0.7647	0.8176
전체 공통 (채택)	3.90	3.62	1.1배	0.7647	0.8181

판단 근거

언어별 표준편차는 성능 이득이 없었습니다. 이득이 없는데 버그가 생기는 쪽을 택할 이유가 없어 가장 단순한 방식을 골랐습니다.

수정 후 — 모든 언어가 같은 글자수에 같은 값을 받습니다.

언어	표본	200자	2000자	8000자
english	67,115	+0.28	+3.84	+10.00
norwegian	197	+0.35	+3.90	+10.00
arabic	1	+0.31	+3.86	+10.00
미수집 언어 (히브리어 등)	0	+0.31	+3.86	+10.00

추가 안전장치 — `Z_CLIP = 10.0` 으로 값의 범위를 제한합니다. 학습 데이터에서 여기 걸리는 것은 **261행(0.19%)** 이고 전부 3,000자 이상 리뷰라, "엄청 길다" 는 의미는 잘려도 보존됩니다.

트리 모델은 값의 크기가 아니라 순서만 보므로 영향이 없습니다. 그러나 **로지스틱회귀·MLP 는 값을 계수에 곱하므로**, 이 변수 하나가 예측을 지배할 수 있어 상한이 필요합니다.

3-5. 급증 구간 — 1열

컬럼	계산식	비율
<code>is_spike</code>	그날 그 게임의 리뷰 수가 평소(중앙값)의 3배 이상인가	8.6%

설계 의도 — 스팀 세일이 이탈에 영향을 줄 수 있다는 팀 내 제안에서 출발했습니다. 다만 세일 날짜 표를 외부에서 가져오는 대신, **데이터에서 직접 "리뷰가 몰린 날"을 탐지**하는 방식을 택했습니다. 이 방식은 세일뿐 아니라 대형 업데이트·DLC 출시·화제성 급증을 모두 포착합니다.

사례	날짜	리뷰 수	평소	배수
DJMAX RESPECT V	2025-06-12	1,072건	8건	134배
The Texas Chain Saw Massacre	2025-05-14	92건	5건	18배

598일이 급증일로 판정되었고 해당 리뷰 11,967건(8.6%)이 표시되었습니다. 급증일 리뷰의 이탈률은 **38.5%** 로, 평소(41.4%)보다 **2.9%p** 낮았습니다.

4 행 제거 내역

사 유	건 수	비 율
리뷰 후 플레이 시간이 음수	9건	0.006%

`playtime_forever < playtime_at_review` 인 경우로, 스팀 측 기록 오류로 판단하여 제거했습니다.

점 검 항 목	결 과
결측치	0
리뷰 중복	0
같은 유저·게임 중복	0

5 변수 묶음 두 종류

평가 방식에 따라 사용할 변수 묶음이 달라집니다.

	A 셋	B 셋
변수 수	25	24
게임 이름 <code>game</code>	포함	제외
사용 목적	랜덤 분할 평가	게임 단위 분할 평가

근거 — 게임 단위로 train/test를 나누면 학습에 없던 게임이 시험에 등장합니다. 이때 게임 이름은 처음 보는 값이므로 정보가 되지 못합니다. 대신

`genre_group` · `era` · `grade` · `game_age_days` 등 **게임의 속성**으로 판단해야 처음 보는 게임도 예측할 수 있습니다.

변 수 묶 음	랜덤 분할	게임 단위 분할
A셋 (게임 이름 포함)	0.820	0.754
B셋 (게임 속성만)	0.817	0.748

해 석

게임 이름을 제거해도 성능이 유지된다는 것은, 모델이 **게임 이름을 암기한 것이 아니라 게임 속성을 학습했음**을 시사합니다.

6 최종 컬럼 목록 — 30열

식 별 용 - 모 델 입 력 아 님

4

recommendationid appid steamid game

모 델 입 력 - 수 치

10

hours_at_review log_hours_at_review log_num_games log_num_reviews game_age_days
review_len review_words review_len_z excl_ratio caps_ratio

모 델 입 력 - 0/1

9

voted_up steam_purchase received_for_free early_access steam_deck is_private
is_spike has_text has_repeat

모 델 입 력 - 범 주

5

language 30 genre_group 5 era 4 grade 4 release_year 18

정 답 · 딥 러닝 용 원 문

2

churn review

7 재현성 · 버전 관리

항 목	내 용
원본	03_수 집 /steam_raw.csv — 수정 금지
전처리	04_전 처리 /preprocess.py
실행	uv run python preprocess.py
결과	dataset.csv · lang_stats.json · dataset_meta.json

원본만 있으면 언제든 동일한 결과를 재생성할 수 있습니다. 전처리 기준을 변경할 경우(예: 이탤 판정 1시간 → 2시간) preprocess.py 의 CHURN_HOURS 상수 한 곳만 수정하면 됩니다.

버전 관리

전처리 규칙이 바뀌면 VERSION 을 올리고 CHANGELOG 에 사유를 적습니다. 실행하면 dataset_meta.json 이 함께 생성됩니다.

```
{ "전처리_버전": "1.2", "이번_변경": "리뷰 길이 표준편차를 전 언어 공통으로 ...",  
  "생성일시": "2026-08-26 16:26", "행수": 139658, "이탈률": 0.4112 }
```

모델·화면 담당자가 자기 파일이 최신인지 눈으로 확인할 수 있어야 하기 때문입니다. 파일 크기가 68MB라 매번 다시 받게 하면 팀 전체가 시간을 낭비합니다.

버 전	날 짜	변 경
1.0	2026-08-25	최초 — 라벨·파생변수 15열, 누수 8열 제외
1.1	2026-08-26	표본 30건 미만 언어의 길이 기준을 전체 통계로 대체 (§3-4). dataset.csv 1행 변동
1.2	2026-08-26	리뷰 길이 표준편차를 전 언어 공통으로 변경 + Z_CLIP = 10 (§3-4). 성능 지표 변동 없음

이 구조가 실제로 작동한 사례

v1.1 수정에서 "139,658행 중 1행만 달라졌다"를 확인할 수 있었던 것 자체가 이 구조의 효과입니다. 원본이 보존돼 있고 전처리가 한 파일에만 있어서, 예전 방식으로 다시 계산해 비교할 수 있었습니다.

전처리가 노트북 셀에 흩어져 있었다면 영향 범위를 알 수 없어 팀원 3명이 각자 작업을 다시 해야 했을 것입니다.

8 후속 확인 예정 항목

항 목	내 용
라벨 기준 민감도	이탈 판정을 0.5 / 1 / 5시간으로 변경해 결론이 유지되는지
관측 창 민감도	90 / 180 / 270일로 변경해 확인
불균형 처리	<code>class_weight</code> vs SMOTE 비교 — SMOTE는 분할 이후에만 적용
게임 단위 분할 편차	조각별 AUC가 0.688~0.829로 변동. 평균과 편차 함께 보고
표본 적은 언어	아랍어 1건. 재수집 시 30건 미만 언어가 늘어나는지 확인
완주 vs 이탈 구분	게임별 평균 클리어 시간을 확보해 "다 깨서 종료"를 분리할 수 있는지 (§3-1)
게임별 이탈률 분산	9.7~88.8%. 게임 속성만으로 이 분산을 얼마나 설명하는지